

Fase 0 · Reconhecimento — Absenteísmo no Trabalho

Data: 26/09/2026 · Janela de dados: base inteira (jul/2007–jul/2010, 740 linhas) · v1

Em três linhas

Reconstruí o processo que gera cada linha, confirmei que a granularidade é mista (evento de ausência dentro de funcionário) e mais irregular do que o previsto — um ID (29) mistura dois funcionários fisicamente diferentes — e que "Work load Average/day" e "Hit target" são mesmo variáveis de nível-mês/empresa, não de funcionário, evidenciado pela contagem de valores distintos por mês (≈ 3 , batendo com os 3 anos que a base cobre sem coluna de ano). Encontrei ainda 34 linhas duplicadas e 43 linhas com "Reason for absence" = 0, quase todas ligadas a falta disciplinar. Tollgate: **APROVADO com ressalvas** — nenhuma delas impede seguir para o Define, mas todas mudam decisões concretas lá.

O que foi feito

1. Perfilamento estrutural do CSV bruto com `scripts/00_reconhecimento.py` (forma, tipos, nulos, duplicatas, constância de atributos por ID, contagem de valores distintos de Work load/Hit target por mês, resíduo da fórmula de BMI, distribuições de categóricas). Saída completa em `artefatos/perfil_estrutural.json`.
2. Leitura de `data/raw/Attribute Information.docx` para confirmar a definição oficial de cada coluna (categorias do "Reason for absence", codificação de "Day of the week", "Education").
3. Busca de fontes oficiais (Banco Central e IBGE) para a linha do tempo de eventos externos.

Nenhuma correlação, cruzamento ou teste de relação entre colunas foi feito nesta fase (F9) — só estrutura, procedência e granularidade.

1 · SIPOC reverso

Etapa	Descrição	Evidência
Fornecedor	O funcionário (gera o evento de ausência) e a área médica/administrativa da transportadora (registra e classifica)	[INFERÊNCIA]
Entrada	Comparecimento esperado ao trabalho num turno programado	[INFERÊNCIA — não há coluna de escala ou turno]

Etapa	Descrição	Evidência
Processo	Evento de ausência ocorre → é classificado por motivo (CID ou administrativo) → é registrado com data (mês/dia/estação), duração em horas e se houve falta disciplinar	[EVIDENTE NO DADO] as colunas Reason for absence, Month of absence, Day of the week, Disciplinary failure, Absenteeism time in hours
Saída	Um registro de ausência com motivo, duração e enquadramento disciplinar	[EVIDENTE NO DADO]
Cliente	A gestão de RH/operações da transportadora, que precisa cobrir o turno e decidir se há penalidade	[INFERÊNCIA]

Etapas que o dado **não registra** (F1): quem substituiu o funcionário ausente, se houve atestado médico anexado (só o código CID), a escala/turno original, o custo da ausência para a operação, e — crucial para Seis Sigma clássico — os dias efetivamente trabalhados (não há denominador para taxa).

2 · Linha do tempo de uma unidade (F2 — vazamento)

Narrativa de uma linha: o funcionário já existe com seus atributos fixos (Transportation expense, Distance, Service time, Age, Education, Son, Social drinker/smoker, Pet, Weight, Height, BMI) → ocorre a ausência → ela é classificada por motivo → é registrada com mês, dia da semana e estação → é somada em horas → se for falta sem justificativa aceita, "Disciplinary failure" é marcado.

Duas perguntas específicas:

- **Alguma medida já está líquida de outra?** Sim — "Body mass index" é calculado de "Weight" e "Height" ($IMC = \text{peso} / (\text{altura}/100)^2$). Recalculei e o resíduo é menor que 1 unidade em 98,6% das linhas (artefatos/perfil_estrutural.json, `circularidade_bmi`) — a diferença residual é só arredondamento. **As três colunas contam como uma evidência só**, nunca três preditores concorrentes (regra do contexto mestre).
- **Que colunas só existem após o desfecho?** "Disciplinary failure" e "Absenteeism time in hours" só podem ser preenchidas depois que a ausência aconteceu e foi avaliada — nenhuma das duas é utilizável como preditor de si mesma nem de "Reason for absence" (que é concomitante). Isso não é vazamento neste projeto porque não há modelo preditivo de curto prazo sendo construído, mas fica registrado para a fase de Modelagem, se houver.

Não há coluna com timestamp de registro (data de digitação) versus data do evento — não dá para medir atraso de registro.

3 · Teste de armadilha prioritária — granularidade e circularidade

Esta é a armadilha mais grave detectada e muda decisões de Define e Measure.

3.1 A granularidade é mais irregular do que o contexto mestre assumia. Testei se cada "atributo fixo do funcionário" é de fato constante dentro do mesmo ID. Onze de doze colunas são constantes para 35 dos 36 IDs. O **ID 29** quebra a regra em todas elas ao mesmo tempo: 1 linha tem Age=28, Height=169cm, Weight=69kg, Education=1 (ensino médio), Son=1; as outras 4 linhas do mesmo ID têm Age=41, Height=182cm, Weight=94kg, Education=4 (mestrado/doutorado), Son=2. Uma pessoa não cresce 13cm nem envelhece 13 anos em uma janela de 3 anos — isso não é deriva natural de atributo (o que seria esperado para Age ou Service time crescendo 1-3 no período), **é o mesmo número de ID reaproveitado para duas pessoas fisicamente diferentes** [DADO, alta confiança — 3 colunas antropométricas incompatíveis simultaneamente]. Efeito prático: os "36 funcionários" da ficha são na verdade 37 pessoas; o holdout aleatório estratificado por ID (regra do contexto mestre) vai colocar as 5 linhas do ID 29 inteiras de um lado do corte, misturando duas pessoas — **decisão a levar ao Define**: dividir ID 29 em 29a/29b pela combinação de Age/Height/Weight, ou excluir a linha minoritária (a única com o perfil "jovem") e documentar a perda de 1 registro.

3.2 Work load Average/day e Hit target são de nível-mês (provavelmente empresa), não de funcionário — confirmado, não só suspeitado. Dentro do mês mais frequente (87 linhas), "Work load Average/day" assume só 3 valores distintos e "Hit target" também só 3 — para dezenas de funcionários diferentes no mesmo "Month of absence". Isso é exatamente o padrão esperado se a coluna é uma métrica da operação inteira, medida uma vez por mês-calendário, e a base cobre **3 anos sem coluna de ano**: "Month of absence" = 7 mistura julho/2007, julho/2008 e julho/2009, cada um com seu próprio valor de carga de trabalho — daí os ~3 valores por rótulo de mês (média de 2,92 valores distintos por mês em 13 categorias de mês, incluindo o mês "0"). **Consequência para o Define**: estas duas colunas não podem entrar como preditor por linha de um modelo de funcionário sem, no mínimo, ser tratadas como efeito de período partilhado — usá-las lado a lado com atributos de funcionário como se fossem da mesma natureza é outra camada da armadilha de granularidade misturada, exatamente como o contexto mestre já antecipava, e este teste a confirma.

3.3 Qualidade adicional que emergiu da checagem estrutural (não corrigida aqui — registrada para o Measure 2A): - 34 linhas são duplicatas exatas nas 21 colunas; olhando o grupo completo (contando também a primeira ocorrência), 60 linhas pertencem a algum grupo duplicado, concentradas em só 9 IDs. Ex.: ID 3 repete a combinação (Reason=27 "consulta odontológica", mesmo mês, mesmo dia da semana, mesma duração) várias vezes. Pode ser (a) coincidência plausível — poucos valores possíveis por evento de rotina curto — ou (b) duplicação de digitação. Não decido isso aqui: é tarefa da auditoria de qualidade (Measure 2A, dimensão Unicidade). - "Reason for absence" = 0 aparece em 43 linhas. O valor 0 **não existe** na lista oficial do UCI (que vai de 1/I a 28); ele coincide com "Disciplinary failure" = 1 em 40 dessas 43 linhas (as outras 3 têm também "Month of absence" = 0 e 0 horas de ausência — parecem registros administrativos incompletos, não eventos de ausência de fato). Ou seja: **falta disciplinar não usa código CID nem o código 26 ("unjustified absence")** — usa um valor reservado (0). Isso é central para a definição de defeito no item 5.

4 · Atores e incentivos (F3)

- **O funcionário** decide se falta e escolhe (ou recebe) o motivo declarado. Incentivo: motivos médicos (CID) não geram punição; "unjustified absence" (26) e o valor reservado 0 (ligado a "Disciplinary failure") geram. Isso cria incentivo para que uma ausência ambígua seja registrada com CID sempre que possível — um viés de registro que nenhum teste estatístico revela sozinho (F3), e que a instituição não teria como policiar sem exame médico presencial.
- **Quem classifica e digita o motivo** (RH ou área médica, [INFERÊNCIA] — não há coluna que identifique o registrador) tem interesse em manter a consistência do CID informado, mas não necessariamente em auditar a veracidade do atestado.
- **A gestão direta** decide sobre "Disciplinary failure": aplica a falta disciplinar quando julga a ausência não justificada. Esse julgamento é a fonte mais provável do padrão descrito em 3.3 (reason=0 quase sempre junto de disciplinary=1).

5 · Defeito — candidatos e recomendação (F6)

Candidato	Definição operacional	Vantagem	Problema
A — Falta disciplinar	Disciplinary failure = 1	Já existe no dado, sem premissa inventada; liga a governança	Muito raro (40/740 = 5,4%) e é consequência de um julgamento humano prévio (circular com o próprio ato de punir), não uma medida direta do processo de ausência
B — Ausência sem lastro médico (evitável em potencial)	Reason for absence ∈ {0, 22, 23, 24, 25, 26, 27, 28} (falta disciplinar + as 7 categorias sem CID) vs. Reason ∈ {1..21} (capítulos CID)	Já existe no dado; separa o que é, em princípio, agendável/administrável (consulta, exame, falta injustificada) do que é doença atestada; acionável — RH pode agir sobre agendamento, não sobre doença	A fronteira tem zona cinzenta: "unjustified absence" (26, n=33) e reason=0 (n=43, ligado à falta disciplinar) não são a mesma coisa que "consulta médica" (23, n=149) ou "consulta odontológica" (28, n=112) — juntar as duas debaixo de "evitável" precisa de definição explícita de borda, feita no Define

Candidato	Definição operacional	Vantagem	Problema
C — Duração fora do padrão (limite de especificação)	Absenteeism time in hours acima de um limiar (ex.: 8h = 1 dia)	Casa com Cp/Cpk clássico	O limite não está no dado — precisaria ser declarado como premissa (ex.: "mais de 1 dia" ou "mais de 3 dias" segundo alguma norma trabalhista), e eu não tenho essa norma confirmada ainda

Recomendo o candidato B, com a fronteira fina que falta ser resolvida no Define: dentro de "sem lastro médico", separar "unjustified absence + falta disciplinar" (claramente evitável, comportamental) de "consulta/exame/doação de sangue/fisioterapia" (evitável só na forma — pode ser agendado fora do expediente — não no mérito). Essa é a decomposição evitável/não-evitável que o contexto mestre já define como o ângulo livre do projeto (ver item 9, Saturação). O candidato A fica como sub-métrica dentro de B, não como defeito principal, porque é raro demais para sustentar um Pareto sozinho (regra F6 e critério 7 da triagem).

Decisão de unidade (granularidade): o defeito é definido no nível do **evento de ausência** (a linha), não do funcionário. Um funcionário com uma ausência evitável e nove legítimas tem 1 evento não conforme em 10, não uma "pessoa não conforme" — evita a armadilha de tratar o funcionário inteiro como unidade quando o que varia é o evento. Consequência: toda estatística de posição sobre o funcionário (ex.: "funcionário X falta mais") precisa declarar se é sobre contagem de eventos ou sobre horas somadas, porque um único evento de 120h (o máximo observado) domina a soma sem dominar a contagem.

6 · CTQ (características críticas para o cliente do processo)

O "cliente" aqui é a operação da transportadora, que precisa de cobertura de turno previsível. Tensão central: **reduzir a ausência evitável x não desincentivar a ausência por doença real**. Um CTQ que otimizasse só "menos horas de ausência" empurraria contra atestados médicos legítimos — exatamente o guardrail permanente do contexto mestre. CTQs candidatos: (1) proporção de eventos evitáveis sobre o total de eventos; (2) previsibilidade do dia da semana em que a ausência evitável concentra (afeta escala); (3) tempo entre eventos evitáveis por funcionário (frequência), separado da duração.

7 · Gemba documental — benchmarks a buscar

Não há taxa de absenteísmo calculável aqui (sem denominador de dias trabalhados) — então benchmark de "taxa setorial de absenteísmo" **não é comparável** a este dado, ainda que exista publicado. O que vale buscar:

- Termos: "absenteísmo" "transporte de cargas" Brasil pesquisa CNT, FGV IBRE absenteísmo indicadores RH Brasil, "unjustified absence" logistics

benchmark, para meta **interna** (melhor quartil de funcionário/mês observado neste próprio dado), já que benchmark externo de taxa não se aplica.

- Tipo de fonte: pesquisas setoriais de RH (ex.: Fundação Instituto de Pesquisas Contábeis, Atuariais e Financeiras — FIPECAFI/USP; CNT — Confederação Nacional do Transporte) e não boletins internacionais de "taxa de absenteísmo", que usam denominador diferente e país diferente.

8 · O que o dado não registra (e o efeito de cada ausência)

Ausência	Efeito sobre o que se pode concluir
Dias efetivamente trabalhados / escala	Nenhuma taxa de absenteísmo é calculável; toda métrica é condicional a "dado que uma ausência ocorreu"
Ano da ocorrência	Sazonalidade mistura 3 anos; qualquer leitura de padrão por mês é hipótese, não conclusão fechada
Contrafactual (o que aconteceria sem a ausência)	Nenhum ganho de uma recomendação pode ser apresentado como líquido — a fase Improve precisa usar ponto de indiferença, não ganho bruto
Identificação de quem cobriu o turno / custo da cobertura	Não dá para monetizar o impacto operacional direto, só o tempo perdido
Registro médico além do capítulo CID (gravidade, recorrência da doença)	Não dá distinguir, dentro de um capítulo CID, doença aguda de crônica

9 · Linha do tempo de eventos externos (F10)

O período (jul/2007–jul/2010) atravessa a crise financeira global de 2008–2009. Fontes oficiais:

Data	Evento	Fonte
Set-dez/2008	Selic mantida no pico de 13,75% a.a. (resposta inicial de cautela)	Banco Central do Brasil, Boletim/Relatório Anual 2009
4º tri/2008	PIB brasileiro recua 3,6% (início da recessão técnica)	IBGE, Contas Nacionais Trimestrais
1º tri/2009	PIB recua mais 0,8%	IBGE, Contas Nacionais Trimestrais
Ao longo de 2009	Selic cai de 13,75% para 8,75% a.a., em resposta à crise	Banco Central do Brasil
Ano de 2009 (fechado)	PIB do ano cai 0,2% ante 2008 (pior resultado desde 1992)	IBGE

Data	Evento	Fonte
4º tri/2009	Recuperação: PIB cresce 4,3% ante mesmo trimestre de 2008	IBGE

[HIPÓTESE A VERIFICAR, não fato]: se a recessão de out/2008–meados/2009 coincidiu com mudança na frequência ou no tipo de ausência (ex.: mais faltas disciplinares por insegurança no emprego, ou menos ausência por medo de demissão — os dois sentidos são plausíveis na literatura de risco moral e incentivo, Varian/Pindyck-Rubinfeld), isso teria que aparecer nos meses que caem dentro dessa janela. **O problema estrutural:** como "Month of absence" não tem ano, não dá para saber se uma linha com mês=10 é outubro/2007, outubro/2008 (auge da crise) ou outubro/2009. Ou seja, **a base não permite testar esta hipótese com rigor** — só permite registrá-la como limitação e como possível explicação rival qualitativa se algum padrão anômalo aparecer no Analyze. Fica marcada aqui para não ser esquecida, e para não ser atribuída depois a um "efeito de mês" sem esta ressalva.

10 · Tipo de projeto

Diagnóstico — entender onde e por que o processo de ausência varia, e separar o evitável do não-evitável — não previsão. Confirma a leitura do contexto mestre sobre saturação: o ângulo de regressão para prever "Absenteeism time in hours" já foi exaustivamente explorado publicamente; este projeto não constrói esse modelo. Não há modelo supervisionado central neste projeto; `references/modelagem.md` não se aplica além de, eventualmente, um modelo de efeitos mistos na fase Analyze para separar variação entre-funcionário de variação dentro-funcionário — não para prever, para decompor variância.

11 · Comparabilidade entre países

Não se aplica — um só país, uma só unidade (transportadora em Brasília).

Registro de escolhas

Escolha	O que usei	O que mais considere	Por que esta	Evidência	Regra
Defeito candidato recomendado	B — ausência sem lastro médico (CID vs. não-CID)	A — falta disciplinar isolada; C — limite de horas	A é raro demais para Pareto (5,4%); C exige premissa de limite que não tenho como sustentar ainda	<code>reason_for_absence_contagem</code> em <code>artefatos/perfil_estrutural.json</code>	

Escolha	O que usei	O que mais considere	Por que esta	Evidência	Regra
Unidade de análise do defeito	Evento de ausência (linha)	Funcionário (linha agregada)	O que varia é o evento; agregar por funcionário already é decisão da fase de baseline, não do Define do defeito	Seção 3.1 e 5 deste relatório	F1, F6
Tratamento do ID 29	Registrar como achado a decidir no Define (dividir ou excluir)	Corrigir silenciosamente agora	Corrigir sem registrar violaria a regra de honestidade de portfólio — a decisão pertence a quem conduz o projeto	constancia_atributos_por_id em artefatos/perfil_estrutural.json	F5, regra 9 do contexto mestre

Números

Todos os números citados acima vêm de `artefatos/perfil_estrutural.json`, gerado por `scripts/00_reconhecimento.py` a partir de `data/raw/Absenteeism_at_work.csv` (740 linhas, 21 colunas, hash abaixo no manifesto).

Tollgate 0

Critério	Veredito	Motivo
Processo reconstruível (triagem 1)	OK	SIPOC reverso montado, com etapas ausentes explicitadas
Unidade de análise (triagem 2)	RESSALVA	Granularidade mista confirmada e mais irregular que o previsto (ID 29); decisão final vai para o Define
Defeito definível (triagem 3)	OK	Candidato B recomendado, com fronteira a fechar no Define
Eixo temporal (triagem 4)	RESSALVA FORTE	Sem coluna de ano; carta de controle e holdout temporal ficam inviabilizados, conforme já previsto no contexto mestre

Critério	Veredito	Motivo
Dimensões de estratificação (triagem 5)	OK	Reason for absence, Day of the week, Seasons, Education, Disciplinary failure — ≥ 3 categóricas utilizáveis
Procedência (triagem 6)	OK, com ressalva pontual	Dado real e documentado (UCI); encontrado 1 ID corrompido (29) e 34 duplicatas exatas a resolver no Measure 2A
Volume x efeito (triagem 7)	A CALCULAR NO DEFINE	Depende do efeito mínimo acionável, ainda não definido
Teste do cheque (triagem 8)	OK	Gestor de RH/operações da transportadora pagaria para saber onde a ausência evitável concentra e agiria sobre agendamento/escala
Saturação (triagem 9)	OK	Ângulo de regressão preditiva descartado por saturação; ângulo de variação/capabilidade e decomposição evitável/não-evitável mantido como livre

Veredito: APROVADO com ressalvas. As ressalvas (ID 29, granularidade de Work load/Hit target, ausência de ano, 34 duplicatas, fronteira do defeito B) não impedem o Define — mas cada uma vira uma decisão explícita lá, não um detalhe a resolver depois.

Pendências e riscos

- Decidir no Define: o que fazer com ID 29 (dividir em duas identidades ou excluir a linha minoritária).
- Decidir no Measure 2A: se as 34 linhas duplicadas são coincidência plausível ou erro de digitação — e o que fazer com cada caso.
- A fronteira exata do defeito B (o que entra em "evitável" além de 26 e do reason=0) precisa ser fechada e travada antes de qualquer contagem de defeito.
- A hipótese da crise de 2008–2009 não é testável com rigor nesta base (sem ano) — mantê-la só como explicação rival qualitativa, nunca como achado.

Para a próxima fase

O Define recebe: o defeito candidato B com sua fronteira em aberto, a decisão pendente sobre ID 29, a confirmação de que Work load Average/day e Hit target são de nível-mês/empresa (não usar como atributo de funcionário sem tratamento de efeito de período), e a lista de duplicatas a resolver no Measure — não antes, porque resolver duplicata já é decisão de qualidade, não de escopo.