

Pré-registro — Fase 1 · Define

Datado em 26/09/2026. Este arquivo é IMUTÁVEL a partir deste commit. Qualquer correção futura é adendo datado ao final do arquivo — nunca edição silenciosa do que está abaixo. Ele existe para provar que as hipóteses, o efeito mínimo e o corte de confirmação vieram antes de qualquer teste de relação entre variáveis (regra 3 do contexto mestre; D8 da `metodo-dmaic`).

Decisões de escopo que este pré-registro assume (fechadas nesta fase, ver

`relatorio.md` para o raciocínio completo)

- Defeito B = evento com "Reason for absence" fora dos capítulos CID (1-21), dividido em **B1 comportamental/disciplinar** (Reason $\in \{0, 26\}$) e **B2 administrável na forma** (Reason $\in \{22, 23, 24, 25, 27, 28\}$).
- Excluídas da população de análise: 3 linhas com Month of absence = 0 e Absenteeism time in hours = 0 (IDs 4, 8, 35 — registros administrativos sem evento real) e 1 linha do ID 29 (Age=28/Height=169/Weight=69, Reason=0/Disciplinary failure=1/0h) — a linha que quebrava a constância dos atributos fixos do ID 29 na Fase 0. População final: **736 eventos, 36 identidades de funcionário**.
- Métrica primária: **proporção de eventos B (B1+B2) sobre o total de eventos** — contagem, não soma de horas, porque um único evento de 120h domina a soma sem dominar a contagem (Fase 0, seção 5). Horas entram como métrica secundária/guardrail, reportada separadamente por subcategoria.
- Granularidade: evento (linha) é a unidade. Toda estatística "por funcionário" é obtida por agregação explícita a partir do evento, e todo teste usa erro-padrão agrupado por ID ou agregação prévia — nunca trata as 736 linhas como independentes.

Holdout — definido agora, aberto uma única vez na fase Control

Aleatório estratificado por identidade de funcionário, sobre as 36 identidades já corrigidas (não por linha isolada). Proporção 75/25: aproximadamente 27 funcionários na janela de exploração, 9 na quarentena de confirmação, sorteio com semente fixa registrada no manifesto desta fase para reprodutibilidade. Declarado como **mais fraco que um corte temporal** (D9): não testa estabilidade ao longo do tempo, só generalização entre funcionários. Proibido de ser lido, carregado ou inspecionado antes da fase Control (regra do contexto mestre).

Correção para múltiplos testes

Quatro hipóteses pré-registradas abaixo, todas decisivas para o projeto (nenhuma é exploração ampla de muitas variáveis) → **Bonferroni** (D10): α ajustado = $0,05 / 4 = 0,0125$ por teste.

Hipóteses pré-registradas

H1 — PRINCIPAL

Enunciado direcional. Entre os 402 eventos B2 (administráveis na forma: consulta médica, exame, doação de sangue, fisioterapia, consulta odontológica), a proporção de funcionários com "Distance from Residence to Work" acima da mediana da amostra é maior do que entre os eventos CID (1–21), em pelo menos 10 pontos percentuais.

Origem. [INSPEÇÃO ESTRUTURAL] — nasceu do CTQ da Fase 0 (deslocamento como fricção de agendamento), não de teoria ou benchmark externo. Vale menos como evidência causal, e isso fica registrado.

Teste planejado. Comparação de duas proporções (funcionários com distância acima/abaixo da mediana) entre o grupo de eventos B2 e o grupo de eventos CID, com erro-padrão agrupado por ID de funcionário (a distância é constante por funcionário — regra de granularidade). Teste de proporções com correção de cluster ou regressão logística com erro-padrão agrupado (cluster-robust por ID). **Efeito mínimo acionável.** 10 pontos percentuais de diferença — abaixo disso, uma política de agendamento baseada em distância não mudaria decisão de RH.

H2 — RIVAL ESTRUTURAL (obrigatória, testada antes de H1)

Enunciado direcional. A diferença observada em H1, se existir, é composição de mix: concentrada nos poucos funcionários com maior número total de eventos (a distribuição de eventos por funcionário tem média 20,5 e desvio 23,7 — Fase 0), não um efeito causal da distância em si sobre o tipo de evento. **Origem.** [INSPEÇÃO ESTRUTURAL] — da própria forma da distribuição de linhas por ID observada no perfilamento da Fase 0. **Teste planejado.** Como "Distance from Residence to Work" é constante por funcionário (não varia dentro do mesmo ID), o teste de composição de mix não pode ser feito por decomposição dentro-de-funcionário. Em vez disso: (a) recalculer o resultado de H1 excluindo, um de cada vez, os 3 funcionários com mais eventos totais, e verificar se o efeito se sustenta; (b) comparar o efeito bruto (todos os funcionários) com o efeito ponderado por funcionário (cada ID conta uma vez, não uma vez por evento) — se divergirem, reportar a versão ponderada por funcionário como a que orienta decisão (regra do Paradoxo de Simpson, [armadilhas.md](#) item 4). **Efeito mínimo acionável.** Se o efeito de H1 cair abaixo de 10 p.p. ao excluir qualquer um dos 3 funcionários mais frequentes, ou se inverter entre a versão bruta e a ponderada por funcionário, H1 é considerada não sustentada pela evidência — é composição de mix, não fator causal.

H3 — Artefato de registro (reason = 0)

Enunciado direcional. Os 39 eventos com "Reason for absence" = 0 e "Disciplinary failure" = 1 (após excluir a linha do ID 29) estão dispersos por muitos funcionários diferentes (mais de 5 IDs distintos respondendo por menos de 50% dos casos cada), consistente com um código de registro administrativo usado pontualmente, e não com um pequeno grupo de funcionários reincidentes. **Origem.** [INSPEÇÃO ESTRUTURAL] — da Fase 0, seção 3.3. **Teste planejado.** Distribuição de frequência dos 39 eventos por ID; calcular a proporção do total concentrada nos 5 IDs mais frequentes nesta categoria.

Efeito mínimo acionável. Se ≤ 5 funcionários responderem por mais de 50% dos 39 casos, a hipótese é refutada (é comportamento concentrado, não artefato disperso do processo) — o que muda o guardrail: passaria a exigir acompanhamento individual, não só

revisão do processo de registro.

H4 — Padrão por dia da semana

Enunciado direcional. Os eventos do defeito B (B1+B2) concentram-se em segunda-feira (Day of the week = 2) e sexta-feira (Day of the week = 6) mais do que os eventos CID, com diferença de pelo menos 8 pontos percentuais na distribuição por dia.

Origem. [TEORIA DE DOMÍNIO, não verificada localmente] — o padrão de "emenda de fim de semana" é citado na literatura geral de gestão de pessoas, mas não tenho experiência de domínio em RH/logística para confirmar que se aplica aqui (contexto mestre, ficha) nem benchmark que o sustente para este setor; a hipótese é levantada por prática comum do campo, não por inspeção dos dados desta base. **Teste planejado.** Comparação da distribuição por dia da semana entre eventos B e eventos CID (qui-quadrado ou teste de proporções por dia), com agregação prévia por funcionário-dia para não inflar n por funcionários com muitos eventos. **Efeito mínimo acionável.** 8 pontos percentuais de diferença na proporção concentrada em segunda+sexta entre B e CID.

Critério de sucesso do projeto (D12)

O projeto vale mesmo que todas as quatro hipóteses acima sejam refutadas: a decomposição evitável/não-evitável do defeito B, feita com o rigor de granularidade que a Fase 0 expôs (evento como unidade, erro-padrão agrupado por funcionário, ID 29 corrigido, Work load/Hit target tratadas como nível de período), já é o achado metodológico central — é o que a maioria dos notebooks públicos deste dataset não faz (Fase 0, seção 10, Saturação). Um resultado nulo em H1/H4, documentado com o mesmo rigor, vale mais para o portfólio do que uma confirmação conveniente.

Adendo datado — correção de número (26/09/2026, mesmo dia do registro original)

Erro encontrado. As duas ocorrências de "36 identidades de funcionário" acima (na declaração da população final, e na definição operacional do holdout) estão **erradas**. O número correto, recontado agora a partir de

`fases/fase-1-define/artefatos/escopo_define.json`
(`n_identicidades_funcionario`), é **34**, não 36.

Causa. A exclusão das 3 linhas administrativas (IDs 4, 8 e 35 — Month of absence = 0, Absenteeism time in hours = 0) remove a única linha que os IDs 4 e 35 tinham na base inteira. Ao excluir essas linhas por não representarem evento real (decisão registrada em `relatorio.md`, item 3), esses dois IDs deixam de existir na população de evento. Restam 34 identidades com pelo menos 1 evento, não 36. O texto original já registrava esse efeito colateral em `relatorio.md` ("por isso 34, não 36, identidades") — o erro ficou só nas duas menções acima, que não foram atualizadas quando o `relatorio.md` foi corrigido.

Efeito sobre o holdout. O sorteio aleatório estratificado por identidade de funcionário deve ser feito sobre **34 identidades**, não 36. Na proporção 75/25 já definida, isso dá aproximadamente **26 funcionários na janela de exploração e 8 na quarentena de confirmação** ($34 \times 0,75 \approx 25,5 \rightarrow 26$; $34 - 26 = 8$) — não 27/9 como o texto original

calculava a partir do número errado. Nenhum sorteio foi executado ainda (o holdout continua fechado até a fase Control), então não há recorte já gerado para refazer — só a regra a seguir quando o sorteio for feito está corrigida aqui.

O que não muda. As 4 hipóteses (H1-H4), a correção de Bonferroni ($\alpha=0,0125$), a proporção 75/25, a semente fixa (a ser definida no momento do sorteio) e o critério de sucesso permanecem como registrados acima — nada além do número de identidades e sua propagação ao cálculo do holdout foi alterado por este adendo.

Hash SHA-256 deste arquivo **antes** deste adendo (histórico, não descartado):
e5a3a86dd132ea7a162060f19f906e5c29ed31231f758a2c905ca1548cacb149 — ver `manifesto.md` para o hash após este adendo.