

Fase 2A · Measure — Procedência e qualidade do dado — Absenteísmo no Trabalho

Data: 26/09/2026 · Janela de dados: `data/processed/eventos_limpos.csv` (736 eventos, 34 identidades — base travada do Define) · v1

Em três linhas

Auditei as seis dimensões de qualidade sobre a base limpa do Define (M2): nenhum nulo, nenhum valor fora de domínio, Work load Average/day e Hit target seguem confirmados como nível-mês, e a circularidade do BMI se mantém. Resolvi a pendência das 34 linhas duplicadas com um teste quantitativo de plausibilidade por grupo: 23 dos 26 grupos são coincidência plausível (mantidos), 3 são suspeitos de erro de digitação (removidos). Base final: **733 eventos, 34 identidades**. Tollgate: **APROVADO**.

O que foi feito

1. Perfilamento de confirmação sobre a base limpa (`scripts/02a_measure_qualidade.py`), verificando que as 4 linhas excluídas no Define não sobrevivem.
2. Auditoria das seis dimensões de qualidade (M2), cada uma com teste e critério de aceite.
3. Resolução da pendência de duplicatas da Fase 0 com um modelo de colisão por acaso (M5 — regra escrita antes de remover qualquer linha).
4. Nomeação dos vieses de seleção e vazamento, e do erro indetectável nesta base.

Como é dado real de uma única transportadora, sem acesso a quem gera o dado, esta fase é **auditoria de procedência**, não MSA clássico com repetibilidade/reprodutibilidade de operador (M4).

Decisões e por quê

1 · Perfil de confirmação

Base limpa: 736 eventos, 34 identidades (72 B1, 402 B2, 262 CID) — idêntico ao que o Define entregou. As 4 linhas excluídas (IDs 4, 8-parcial, 35, e a linha jovem do ID 29) foram confirmadas ausentes: `confirmacao_exclusoes_define` em `artefatos/auditoria_qualidade.json` mostra 0 ocorrências para todos os quatro critérios de checagem.

2 · As seis dimensões

Compleitude (M2, M3) — APROVADO. Zero nulos em todas as 21 colunas. "Month of absence" = 0 e "Reason for absence" = 0 são códigos válidos (o primeiro tratado como categoria residual desde o Define; o segundo já incorporado à subcategoria B1), não ausência de dado — decisão já registrada no Define, apenas reconfirmada aqui.

Unicidade (M2) — RESOLVIDO, com critério quantitativo. A Fase 0 achou 34 linhas em excesso de duplicata (60 linhas em 26 grupos, contando a duplicata de linha inteira). Como o dataset tem só 21 colunas e a maioria é constante por funcionário, um grupo duplicado dentro do mesmo ID se reduz, na prática, a colisão de (Reason for absence, Month of absence, Day of the week, Absenteeism time in hours) — os quatro campos que variam por evento.

Construí um teste de plausibilidade por grupo: para cada categoria de motivo, calculei o **suporte empírico** K_r — quantas combinações distintas de (Month, Day of the week, Hours) o dataset inteiro já mostra para aquele motivo. Para cada funcionário com n_i eventos daquele motivo, a probabilidade aproximada de pelo menos uma colisão por acaso, sorteando n_i vezes entre K_r valores possíveis (problema do aniversário), é $1 - \exp(-n_i(n_i-1)/(2 \cdot K_r))$.

Critério	Veredito
$p_{\text{colisão}} \geq 0,30$	Coincidência plausível — evento de rotina curta com espaço de combinações restrito e funcionário com muitos eventos do mesmo motivo. Mantido.
$p_{\text{colisão}} < 0,30$	Colisão pouco provável por acaso — tratado como erro de digitação provável. Removida a linha extra, mantida a primeira ocorrência.

O limiar de 0,30 é uma escolha de julgamento, não uma convenção estatística padrão — registrado no "Registro de escolhas" abaixo, e reversível se o responsável do projeto discordar.

Resultado: 23 dos 26 grupos ficaram acima de 0,30 (alguns com $p_{\text{colisão}} > 0,95$ — por exemplo, ID 3 com 38 eventos de "consulta odontológica" (Reason 27) contra um suporte de só 35 combinações possíveis: colisão seria quase certa, não é evidência de erro). **3 grupos ficaram abaixo do limiar** — ID 5 (Reason 23, $p=0,009$), ID 27 (Reason 23, $p=0,088$) e ID 34 (Reason 23, $p=0,281$) — removidos (1 linha cada, mantida a primeira ocorrência). Base final: **733 eventos** ($736 - 3$), mesmas 34 identidades (nenhum funcionário tinha só essa linha).

Validade (M2) — APROVADO. Zero valores fora de domínio em Day of the week ($\in \{2..6\}$), Seasons ($\in \{1..4\}$), Education ($\in \{1..4\}$), Reason for absence ($\in \{0..28\}$) e as três binárias (Disciplinary failure, Social drinker, Social smoker).

Consistência (M2) — reconfirmada, não só herdada. (a) Work load Average/day e Hit target seguem em ~3 valores distintos por mês (3,08 e 2,92 em média, 12 meses — nenhum mês caiu para 1 valor único mesmo após as exclusões do Define): a leitura de nível-mês/empresa da Fase 0 se mantém sobre a base limpa. (b) BMI: resíduo < 1 em 98,64% das linhas (praticamente idêntico ao valor da Fase 0, 98,65% — as exclusões não tocaram essas colunas de forma relevante). **Regra operacional travada a partir daqui:** Weight e Height são as colunas- fonte; Body mass index é derivada. Nenhuma fase seguinte usa as três como preditores concorrentes na mesma análise.

Acurácia (M2) — NÃO AUDITÁVEL, declarado. Não há valor total independente (ex.: um sistema de ponto) para conferir a soma de horas ou a contagem de eventos contra

uma fonte externa. Não força verificação artificial.

Pontualidade (M2) — NÃO AUDITÁVEL PARA ATRASO, declarado. Sem timestamp de registro, não há como medir atraso entre o evento e o lançamento (já registrado na Fase 0). A concentração por mês (49 a 87 eventos/mês) não mostra padrão que sugira lançamento em lote além do que a checagem de duplicata já capturou.

3 · Vieses

- **Seleção:** a população é "funcionário com pelo menos 1 evento no período" — quem nunca faltou não aparece. Não há como calcular a proporção de funcionários que faltam, nem quantos existem no total (armadilha #8, `armadilhas.md`).
- **Vazamento:** Disciplinary failure e Absenteeism time in hours são preenchidos depois do evento — nunca usados como preditor de Reason for absence nem um do outro (Fase 0, item 2; reconfirmado aqui sem violação, porque esta fase não constrói modelo).
- **Não representado:** funcionários sem nenhuma ausência no período inteiro existem na transportadora, mas não entram nesta base — são o denominador que falta para qualquer taxa (Fase 0, seção 7).

4 · Erro indetectável

Um "Reason for absence" preenchido por conveniência — por exemplo, uma falta sem justificativa real lançada como "consulta médica" (23) para evitar o enquadramento disciplinar — não deixa rastro estrutural nesta base. Só seria visível com o atestado físico em mãos, que não existe aqui. Isso é particularmente relevante porque é **adjacente à hipótese H3** do pré-registro (o padrão reason=0 como artefato de registro): se o viés for nessa direção, a proporção real de eventos comportamentais pode estar subestimada (parte deles está classificada como B2 ou até CID). Vai para as limitações do README.

5 · Veredito fit-for-purpose

Esta base **não pode responder:** - **Taxa de absenteísmo** — sem dias trabalhados, não há denominador (Fase 0). - **Causalidade da crise 2008-2009** — sem coluna de ano, não há como isolar o período (Fase 0). - **Risco individual por funcionário** — $n=34$ identidades é insuficiente para qualquer scoring com validade estatística. - **O mérito do atestado médico** — só o código CID está disponível, nunca o documento; a base registra a classificação, não a veracidade dela.

Estes não são falhas do trabalho — são limites do instrumento disponível, declarados antes de qualquer conclusão se apoiar neles (M4).

Registro de escolhas

Escolha	O que usei	O que mais considere	Por que esta	Evidência	Regra
Critério de duplicata	Modelo de colisão por acaso (aproximação do problema do aniversário) com limiar $p < 0,30$	Remover todas as 26 duplicatas por precaução; manter todas por não ter certeza	Remover tudo descartaria eventos reais coincidentes (ex.: ID 3 com quase certeza de colisão dado seu volume); manter tudo ignoraria 3 casos estatisticamente improváveis por acaso	artefatos/auditoria/102185	M5 (qualidade.json, un
Limiar de plausibilidade	0,30	0,05 (convenção de significância) ou 0,50 (mais conservador)	0,05 deixaria muitos casos moderadamente improváveis (ex. $p = 0,28$) como "plausíveis" só por não cruzar um limiar arbitrário rígido; 0,30 separa claramente os 3 casos com $p < 0,09$ -0,28 dos 23 casos com $p > 0,39$ — há uma lacuna natural nos dados entre 0,28 e 0,39	artefatos/auditoria/102185	M5 (regra escrita, decisão de julgamento registrada)

Escolha	O que usei	O que mais considere	Por que esta	Evidência	Regra
Regra fonte/derivada do trio Weight-Height-BMI	Weight e Height como fonte; BMI como derivada	Tratar as três simetricamente	BMI é aritmeticamente calculável das outras duas (resíduo<1 em 98,6%); manter simetria esconderia a circularidade em vez de preveni-la	Fase 0, seção 2; artefatos/auditoria_qualidade.json, consistencia.circularidade_bmi	F1 (linha do tempo/circularidade_bmi)

Números

Todos os números vêm de `artefatos/auditoria_qualidade.json`, gerado por `scripts/02a_measure_qualidade.py` a partir de `data/processed/eventos_limpos.csv` (a base travada do Define, não o CSV bruto). A base final pós-qualidade foi salva em `data/processed/eventos_qualidade.csv` (733 linhas, 34 identidades).

Tollgate 2A

Critério	Veredito	Motivo
Seis dimensões com teste e critério de aceite explícitos	OK	Compleitude, Unicidade, Validade, Consistência auditadas com teste; Acurácia e Pontualidade declaradas não auditáveis com motivo, não puladas
Duplicatas com veredito por grupo e evidência quantitativa	OK	26 grupos, cada um com p_colisão calculada; 23 plausíveis mantidos, 3 suspeitos removidos
Work load/Hit target e circularidade BMI reconfirmados na base limpa	OK	Recalculados sobre <code>eventos_limpos.csv</code> , não herdados por citação — valores praticamente idênticos aos da Fase 0
Viés de seleção nomeado como limitação	OK	Item 3 — população condicionada a ter pelo menos 1 evento
Veredito fit-for-purpose com razão estrutural de cada limite	OK	Item 5 — 4 limites nomeados, cada um com a razão

Veredito: APROVADO.

Pendências e riscos

- O critério de remoção de duplicata (limiar 0,30) é uma escolha de julgamento — se o responsável do projeto discordar do limiar, isso muda a base final (733 vs. 736 ou algum número intermediário) e precisa ser revisitado antes da Fase 2B congelar o baseline.
- O erro indetectável nomeado (Reason for absence por conveniência) é adjacente à hipótese H3 do pré-registro — se H3 for refutada no Analyze (comportamento concentrado, não artefato disperso), este erro indetectável ganha peso como explicação alternativa a ser mencionada nas limitações do README.

Para a próxima fase

O Measure 2B recebe `data/processed/eventos_qualidade.csv` (733 eventos, 34 identidades) como base definitiva para o baseline — não mais `eventos_limpos.csv`. A métrica primária (proporção de eventos B) e secundária (horas por subcategoria) definidas no Define continuam válidas; os números brutos preliminares citados no Define (54,4% B, etc.) devem ser recalculados sobre esta base final antes de virarem baseline congelado.