

Fase 2B · Measure — Baseline, estabilidade e capacidade — Absenteísmo no Trabalho

Data: 26/09/2026 · Janela de dados: `data/processed/eventos_qualidade.csv` (733 eventos, 34 identidades — janela de exploração, holdout fechado) · v1

Em três linhas

O baseline da proporção de eventos do defeito B é **64,3%** [57,95%–69,13%], com o intervalo calculado por bootstrap agrupado por funcionário — bem mais largo que o Wilson ingênuo, porque só há 34 clusters, não 733 observações independentes. Omiti a carta de controle por regra (M11: no máximo 12 pontos possíveis, abaixo do mínimo de 20-25), construí capacidade contra meta interna (quartil de melhor desempenho) e dois Paretos na mesma dimensão — com uma régua alternativa obrigatória para B1, cujo impacto em horas é sempre zero. O poder disponível para H1 e H4, calculado sobre 34 clusters, é **muito baixo (≈3%)** — achado central desta fase para o Analyze. Tollgate: **APROVADO**.

O que foi feito

1. Baseline da métrica primária e secundárias, com IC por bootstrap de cluster (`scripts/02b_measure_baseline.py`).
2. Tabela descritiva não temporal por rótulo de mês, no lugar da carta de controle (justificado por regra, não por falta de coluna de ano apenas).
3. Capacidade contra meta interna (quartil de melhor desempenho por funcionário).
4. Dois Paretos na mesma dimensão (Reason for absence detalhado), com régua alternativa para B1.
5. Cálculo de poder sobre o n efetivo de clusters (34 funcionários), não sobre 733 eventos.
6. Congelamento do baseline em `baseline-congelado.md` (IMUTÁVEL a partir deste commit).

Correção declarada sobre a Fase 1: ao calcular este baseline, percebi que o `relatorio.md` do Define somava errado a proporção preliminar de B1+B2 ("54,4%... 44,6% B2" — na verdade B2 era 54,62%, dando 64,4%, não 54,4%). O `artefatos/escopo_define.json` sempre esteve correto; era um erro de digitação na prosa do relatório. Corrigi diretamente o texto do `relatorio.md` da Fase 1 (não é artefato imutável — só o pré-registro e o baseline são) e registro aqui, por transparência, que o número real sempre foi próximo de 64%, batendo com o baseline formal desta fase (64,26%).

Decisões e por quê

1 · Baseline (M6, M7)

Reportei a proporção com **dois** intervalos de confiança, deliberadamente:

- **Wilson ingênuo** (M7), tratando as 733 linhas como independentes: [60,72%; 67,64%] — **não usar para decisão**, porque ignora a granularidade.
- **Bootstrap agrupado por cluster**: reamostrai os **34 funcionários** inteiros (não eventos) 5.000 vezes, recalculando a proporção a cada reamostragem — [57,95%; 69,13%]. Este é o IC que orienta decisão, e é bem mais largo, confirmando que ignorar a granularidade (regra do contexto mestre) subestimaria a incerteza real.

DPMO e nível sigma: 642.565 DPMO, nível sigma -0,365 sem deslocamento (1,135 com o deslocamento convencional de $1,5\sigma$, M16, reportado nos dois formatos). Um nível sigma negativo ou próximo de zero é esperado aqui: o defeito B é maioria do processo (64%), não uma exceção rara — o arcabouço DPMO/sigma foi desenhado para defeitos raros e apresenta números pouco intuitivos quando o "defeito" é a maioria. Isso não invalida a métrica de proporção (que continua o número que importa para decisão), só mostra que DPMO/sigma é um complemento formal aqui, não a métrica central do projeto.

Métricas secundárias — B1 em 9,82% [5,52%; 16,19%] e B2 em 54,43% [44,68%; 61,75%] (M6, M17 — recalculadas a partir das contagens desta fase, não copiadas do Define).

Horas por subcategoria (M6 — distribuição inteira, não só média): B1 tem mediana **0h** (72% dos eventos B1 têm 0 horas — o achado da Fase 1/2A de que reason=0/26 zera a duração se reflete diretamente aqui). B2 tem mediana 2h, cauda até 24h. CID tem a distribuição mais dispersa (desvio 20,48h, máximo 120h) — o outlier que a Fase 0 já havia identificado.

2 · Estabilidade — carta de controle omitida por regra (M8, M9, M11)

Não construí carta de controle. A justificativa não é só "não há coluna de ano" — é uma regra quantitativa: mesmo ignorando a mistura de 3 anos calendário no mesmo rótulo de "Month of absence", o máximo de pontos possíveis seria **13** (rótulos 0 a 12), abaixo do mínimo de 20-25 subgrupos que M11 exige para limites estáveis. Forçar uma carta aqui produziria limites instáveis demais para sustentar qualquer classificação de causa comum vs. especial (M8).

No lugar, produzi uma **tabela descritiva não temporal** (proporção de B por rótulo de mês), com o aviso de que não é série temporal escrito **na própria legenda do gráfico** (artefatos/tabela_ao_temporal_por_mes.png), não só no texto. A proporção varia de 53% (mês 5) a 81% (mês 9) — variação real, mas sem significado cronológico atribuível, porque cada rótulo mistura até 3 anos. Nenhum mês é tratado como sinal de causa especial.

3 · Capabilidade contra meta interna (M16)

Como não há benchmark externo de taxa (Fase 0, seção 7), a meta é a proposta interna já registrada no Define: o quartil de funcionários com melhor desempenho (8 dos 34, os 25% com menor proporção de eventos B) tem proporção média de **33,36%** — bem abaixo do baseline agregado de 64,26%.

Tradução em negócio: ao ritmo observado (~13,1 eventos B por mês, numa aproximação de 36 meses corridos para o período jul/2007–jul/2010 — o denominador de meses é estimado, não contado, porque não há coluna de ano exata), atingir o nível do quartil superior reduziria para ~6,8 eventos B por mês — uma queda aproximada de **6,3**

eventos evitáveis por mês. Este número é sobre o baseline agregado; não é o ganho líquido (isso é trabalho da fase Improve, com ponto de indiferença, dado que não há contrafactual nesta base).

4 · Estratificação e Pareto (M17, M18)

Dimensão: **Reason for absence detalhado** dentro do defeito B (8 códigos: 0, 22, 23, 24, 25, 26, 27, 28) — não só B1/B2 agregado, para não perder onde exatamente a ação de agenda deve mirar.

Pareto de taxa (artefatos/pareto_taxa.png): "consulta médica" (23, 31,0%) e "consulta odontológica" (28, 23,8%) somam 54,8% dos eventos B sozinhas; "fisioterapia" (27, 14,7%) leva a 69,5% acumulado. Os três primeiros códigos (todos B2) já respondem por quase 70% do volume.

Pareto de impacto em horas (artefatos/pareto_impacto_horas.png) — **armadilha declarada**: como 100% dos eventos B1 (reason 0 e 26) têm Absenteeism time in hours = 0 (achado da Fase 1, reconfirmado na Fase 2A), **B1 não pode aparecer neste Pareto** — apareceria com impacto zero, o que esconderia o problema comportamental/disciplinar em vez de revelá-lo. O Pareto de impacto foi construído **só com os 6 códigos de B2**: "consulta médica" (31,3%), "consulta odontológica" (25,1%) e "acompanhamento" (22,0%) somam 78,4% das horas de B2.

Qual orienta a decisão: para B2, os dois Paretos concordam nos dois primeiros lugares (23 e 28 lideram taxa e impacto) — a recomendação da fase Improve pode mirar esses dois com confiança dupla. Para B1, **a única régua disponível é o Pareto de taxa** (contagem de eventos) — horas não existe como métrica para esta subcategoria, e isso precisa ser dito toda vez que B1 for discutido daqui em diante, para não ser lido como "B1 não tem custo".

5 · Tamanho de amostra e poder (M19)

Este é o achado mais importante desta fase para o que vem depois. O n efetivo para os testes de H1 e H4 não é 733 (eventos) — é **34** (funcionários, porque "Distance from Residence to Work" é constante por funcionário, e H4 precisa de agregação prévia por funcionário-dia para não inflar n). Com uma divisão aproximada de 17 funcionários por grupo (mediana de distância) e a correção de Bonferroni ($\alpha=0,0125$):

Hipótese	Efeito mínimo pré-registrado	Poder aproximado com $n=17$ /grupo
H1 (distância $\times$ B2)	10 p.p.	$\approx 2,9\%$
H4 (dia da semana $\times$ B)	8 p.p.	$\approx 2,7\%$

Poder de $\sim 3\%$ é dramaticamente abaixo do convencional (80%). **Isso não invalida o pré-registro** — o efeito mínimo e o teste já estavam decididos antes de eu calcular isso (regra 3, anti-garimpo) — mas significa que um resultado "não significativo" em H1 ou H4 no Analyze **não pode ser lido como "não há efeito"**: com este poder, a ausência de significância é quase garantida mesmo que o efeito exista. O Analyze precisa reportar o efeito observado com seu IC, não só o p-valor, e tratar qualquer "não significativo" como

inconclusivo, não como refutação (D6, M19).

Recortes sem n suficiente (menos de 15 eventos): "doação de sangue" (Reason 24, n=3) — já antecipado como provavelmente raro desde a Fase 0. Nenhum outro código de Reason ficou abaixo desse limiar.

6 · Código e gráficos

Gerados em `scripts/02b_measure_baseline.py` (números) e `scripts/02b_graficos.py` (figuras): proporção com IC (`baseline_proporcoes.png`), os dois Paretos (`pareto_taxa.png` , `pareto_impacto_horas.png`) e a tabela não temporal (`tabela_ao_temporal_por_mes.png` , com o aviso na própria legenda do título).

7 · Congelamento

Ver `baseline-congelado.md` — **IMUTÁVEL a partir deste commit.**

Registro de escolhas

Escolha	O que usei	O que mais considere	Por que esta	Evidência	Regra
Método de IC para a proporção	Bootstrap por cluster (34 funcionários)	Wilson padrão (M7) sobre 733 eventos	Wilson é a convenção (M7), mas ignora a granularidade — reporte os dois, e uso o bootstrap para decisão, seguindo a regra de granularidade que prevalece sobre a convenção quando conflitam	<code>artefatos/baseline.json</code>	M7, granularidade do contexto mestre
Ausência de carta de controle	Tabela descritiva não temporal	Carta I-MR ou p mensal forçada	Máximo de 13 pontos possíveis, abaixo do mínimo de 20-25 (M11) — mesmo ignorando a mistura de anos	Fase 0, seção 4; <code>artefatos/baseline.json</code>	M8, M9, M11

Escolha	O que usei	O que mais considere	Por que esta	Evidência	Regra
Régua de impacto para B1	Contagem de eventos (Pareto de taxa)	Forçar horas com valor 0 no Pareto de impacto	Reportar B1 com impacto-em-horas=0 esconderia o problema em vez de revelá-lo	artefatos/baseline.json, pareto.nota_B1	
Denominador de meses para a tradução de capacidade em negócio	36 meses (aproximação)	Contar meses exatos do período	Sem coluna de ano não há como contar meses exatos — declarado como aproximação, não apresentado como contagem	artefatos/baseline.json, capacidade	regra 5 do contexto mestre (nunca inventar número — aproximação declarada como tal)

Números

Todos os números vêm de `artefatos/baseline.json`, gerado por `scripts/02b_measure_baseline.py` a partir de `data/processed/eventos_qualidade.csv`. Gráficos em `artefatos/*.png`, gerados por `scripts/02b_graficos.py`.

Tollgate 2B

Critério	Veredito	Motivo
Baseline com número, unidade e IC agrupado por funcionário	OK	64,26% [57,95%;69,13%] por bootstrap de 34 clusters — não trata 733 eventos como independentes
Ausência de carta de controle justificada por regra	OK	M11: máximo 13 pontos possíveis, abaixo do mínimo de 20-25
Capabilidade contra meta interna, com tradução em negócio	OK	Quartil superior = 33,36%; tradução ≈6,3 eventos evitáveis/mês a menos
Dois Paretos na mesma dimensão, com limitação de B1 declarada e régua alternativa	OK	Pareto de taxa (8 códigos) e de impacto em horas (6 códigos de B2); B1 fica só no Pareto de taxa, com a razão explícita

Critério	Veredito	Motivo
Poder calculado sobre n efetivo de clusters (34), recortes sem n listados	OK	Poder $\approx 3\%$ para H1 e H4 com $n=17/\text{grupo}$; Reason=24 ($n=3$) sinalizado
Baseline congelado como artefato imutável, com data e filtros	OK	baseline-congelado.md, datado, com janela e filtros declarados

Veredito: APROVADO.

Pendências e riscos

- O poder muito baixo para H1 e H4 ($\sim 3\%$) é uma limitação estrutural do projeto ($n=34$ funcionários), não corrigível nesta base — o Analyze precisa reportar efeito e IC, nunca só significância, e isso precisa aparecer nas limitações do README.
- A tradução de capacidade em "eventos por mês" usa uma aproximação de 36 meses no período — se o responsável do projeto tiver uma contagem mais precisa (ex.: a partir da documentação original do UCI), isso deveria substituir a aproximação antes da Entrega.
- O erro de digitação corrigido no relatório do Define (item acima) não altera nenhuma decisão tomada — só a prosa que descrevia o número preliminar.

Para a próxima fase

O Analyze recebe: o baseline congelado (64,26% de eventos B, com IC), os dois Paretos com a régua diferenciada para B1, e — mais importante — o aviso de poder baixo para H1 e H4, que muda como um resultado "não significativo" deve ser interpretado. A ordem pré-registrada continua valendo: H2 (rival estrutural) antes de H1, depois H3 e H4, com correção de Bonferroni ($\alpha=0,0125$). O holdout continua fechado.